

16.- Feature Selection_05_servicios_completo

June 16, 2023

#

CUxx_Nombre del caso de uso

Citizenlab Data Science Methodology > III - Feature Engineering Domain *** > # 16.- Feature Selection

Feature Selection is the process where you automatically or manually select the most relevant features which contribute most to the correct output of the model.

0.1 Tasks

Perform Selection of Categorical-Input/Categorical-Output

- Encoding-Categorical-Features - Chi-Squared-Feature-Selection - Mutual-Information-Feature-Selection - Evaluate-a-Logistic-Regression-model

Perform Selection of Numerical-Input/Categorical-Output

- ANOVA-F-test-Feature-Selection - Mutual-Information-Feature-Selection - Evaluating-a-Logistic-Regression-model - Tuning-the-Number-of-Selected-Features

Perform Selection of Numerical-Input/Numerical-Output

- Correlation-with-the-outcome-Feature-Selection - Mutual-Information-Feature-Selection - Evaluate-a-Lineal-Regression-model - Tuning-the-Number-of-Selected-Features

Perform Selection of Any-data

- RFE-(Recursive-Feature-Elimination) - Tuning-the-Number-of-Selected-Features - Automatically-Select-the-Number-of-Features

Explore the use of diferent algorithms wrapped by RFE

Explore the use od Hybrid feature selection algorithms

0.2 Consideraciones casos CitizenLab programados en R

- Algunas de las tareas de este proceso se han realizado en los notebooks del proceso 05 Data Collection porque eran necesarias para las tareas ETL. En esos casos, en este notebook se referencia al notebook del proceso 05 correspondiente
- Otras tareas típicas de este proceso se realizan en los notebooks del dominio IV al ser más eficiente realizarlas en el propio pipeline de modelización.
- Por tanto en los notebooks de este proceso de manera general se incluyen las comprobaciones necesarias, y comentarios si procede
- Las tareas del proceso se van a aplicar solo a los archivos que forman parte del despliegue, ya que hay muchos archivos intermedios que no procede pasar por este proceso

- El nombre de archivo del notebook hace referencia al nombre de archivo del proceso 05 al que se aplica este proceso, por eso pueden no ser correlativa la numeración
- Las comprobaciones se van a realizar teniendo en cuenta que el lenguaje utilizado en el despliegue de este caso es R

0.3 File

- Input File: xxxxxxxxxxxx
- Output File: No aplica

0.3.1 Encoding

Con la siguiente expresión se evitan problemas con el encoding al ejecutar el notebook. Es posible que deba ser eliminada o adaptada a la máquina en la que se ejecute el código.

```
[17]: Sys.setlocale(category = "LC_ALL", locale = "es_ES.UTF-8")
```

```
'LC_CTYPE=es_ES.UTF-8;LC_NUMERIC=C;LC_TIME=es_ES.UTF-8;LC_COLLATE=es_ES.UTF-8;LC_MONETARY=es_ES.UTF-8;LC_MESSAGES=en_US.UTF-8;LC_PAPER=es_ES.UTF-8;LC_NAME=C;LC_ADDRESS=C;LC_TELEPHONE=C;LC_MEASUREMENT=C;LC_IDENTIFICATION=C'
```

0.4 Settings

0.4.1 Libraries to use

```
[18]: library(readr)
library(dplyr)
library(tidyr)
library(forcats)
library(lubridate)
```

0.4.2 Paths

```
[19]: iPath <- "Data/Input/"
oPath <- "Data/Output/"
```

0.5 Data Load

OPCION A: Seleccionar fichero en ventana para mayor comodidad

Data load using the {tcltk} package. Uncomment the line if using this option

```
[20]: # file_data <- tcltk::tk_choose.files(multi = FALSE)
```

OPCION B: Especificar el nombre de archivo

```
[21]: iFile <- "CU_34_15_05_servicios_completo.csv"
file_data <- paste0(iPath, iFile)
```

```

if(file.exists(file_data)){
  cat("Se leerán datos del archivo: ", file_data)
} else{
  warning("Cuidado: el archivo no existe.")
}

```

Se leerán datos del archivo: Data/Input/CU_34_15_05_servicios_completo.csv

Data file to dataframe Usar la función adecuada según el formato de entrada (xlsx, csv, json, ...)

```
[22]: data <- read_csv(file_data)
```

Rows: 272862 Columns: 19
Column specification

```

Delimiter: ","
chr      (5): Servicio, CMUN, CDIS, CSEC, NSEC
dbl      (12): Futbol, nservicios, capacidad, tmed, prec, velmedia,
presMax, t1_...
lgl      (1): is_train
date     (1): Fecha

```

Use `spec()` to retrieve the full column specification for this data.

Specify the column types or set `show_col_types = FALSE` to quiet this message.

Estructura de los datos:

```
[23]: data |> glimpse()
```

```

Rows: 272,862
Columns: 19
$ Fecha      <date> 2022-01-12, 2022-01-31, 2022-01-28,
2022-01-06, 2022...
$ Servicio   <chr> "Delivery", "Taxi", "Taxi",
"Delivery", "Delivery", "...
$ CMUN       <chr> "079", "079", "903", "079", "007",
"022", "079", "079...
$ CDIS       <chr> "14", "01", "01", "04", "04", "01",
"16", "01", "16",...
$ CSEC       <chr> "050", "048", "006", "080", "012",
"004", "041", "033...
$ Futbol     <dbl> 1, 0, 0, 0, 1, 1, 0, 0, 0, 0, 1, 0,

```

```

0, 0, 0, 0, 0, 0,...
$ nservicios      <dbl> 58, 5, 0, 14, 60, 50, 13, 4, 3, 9,
68, 12, 0, 1, 14, ...
$ capacidad       <dbl> 80, 69, 56, 80, 70, 56, 80, 69, 69,
69, 80, 80, 69, 6...
$ tmed           <dbl> 7.366319, 8.823406, 7.854915,
4.226603, 4.982656, 7.2...
$ prec           <dbl> -0.009468616, 0.000000000,
0.000000000, 0.010181896, ...
$ velmedia       <dbl> 1.5999961, 1.5114967, 2.2536168,
1.0279945, 1.0387037...
$ presMax        <dbl> 954.7939, 948.9795, 940.2553,
945.1884, 948.9570, 943...
$ t1_1           <dbl> 1094, 1251, 2232, 746, 1080, 2256,
692, 1270, 2229, 8...
$ t3_1           <dbl> 45.4360, 41.6091, 44.2016, 47.1729,
48.5361, 43.2877,...
$ NSEC           <chr> "Madrid - 14.050", "Madrid -
01.048", "Tres Cantos - ...
$ area           <dbl> 38753.96, 15289.89, 124539.78,
89206.78, 24473.30, 34...
$ elevation       <dbl> 658, 635, 719, 710, 693, 710, 702,
635, 690, 710, 690...
$ densidad_hab_km2 <dbl> 28229.3737, 81818.7738, 17921.9842,
8362.5928, 44129....
$ is_train        <lgl> TRUE, TRUE, TRUE, TRUE, TRUE, TRUE,
TRUE, TRUE, TRUE,...

```

Muestra de los primeros datos:

```
[24]: data |> slice_head(n = 5)
```

	Fecha <date>	Servicio <chr>	CMUN <chr>	CDIS <chr>	CSEC <chr>	Futbol <dbl>	nservicios <dbl>	capacidad <dbl>	tmed <dbl>
A spec_tbl_df: 5 × 19	2022-01-12	Delivery	079	14	050	1	58	80	7.366319
	2022-01-31	Taxi	079	01	048	0	5	69	8.823406
	2022-01-28	Taxi	903	01	006	0	0	56	7.854915
	2022-01-06	Delivery	079	04	080	0	14	80	4.226603
	2022-01-21	Delivery	007	04	012	1	60	70	4.982656

0.6 Selecting Categorical Input / Categorical Output

0.6.1 Encoding Categorical Features

0.6.2 Chi-Squared Feature Selection

0.6.3 Mutual Information Feature Selection

0.6.4 Evaluating a Logistic Regression model

Select number of Features to use

[25]: *# Select numer of Features to use*

Operation

0.7 Selecting Numerical Input / Categorical Output

0.7.1 ANOVA F-test Feature Selection

0.7.2 Mutual Information Feature Selection

0.7.3 Evaluating a Logistic Regression model

Selecting feature to use

[26]: *# Select numer of Features to use*

Operation

0.7.4 Tuning the Number of Selected Features

[]:

Know the best number of features to select

[]:

See the relationship between the number of selected features and accuracy

[]:

0.8 Selecting Numerical Input / Numerical Output

0.8.1 Correlation with the outcome Feature Selection

[]:

0.8.2 Mutual Information Feature Selection

[]:

0.8.3 Evaluating a Lineal Regression model

[]:

Selecting feature to use

[27]: *# Select numer of Features to use*

Operation

[]:

0.8.4 Tuning the Number of Selected Features

Know the best number of features to select

See the relationship between the number of selected features and MAE

0.9 Any data: RFE (Recursive Feature Elimination)

0.9.1 RFE for Classification

Selecting feature to use

```
[28]: # Select numer of Features to use
```

Operation

[]:

0.9.2 RFE for Regression

Selecting feature to use

```
[29]: # Select numer of Features to use
```

Operation

[]:

0.9.3 Tuning the Number of Selected Features

RFE for Classification Use dataset as example: diabetes

Selecting feature to use

```
[30]: # Select range [f..l] of Features to evaluate
      f=2
      l=10
```

Operation

[]:

RFE for Regression Selecting feature to use

```
[31]: # Select range [f..l] of Features to evaluate
      f=2
      l=10
```

Operation

```
[ ]:
```

0.9.4 Automatically Select the Number of Features

RFE for Classification

```
[ ]:
```

RFE for Regression

```
[ ]:
```

0.10 Exploring the use of different algorithms wrapped by RFE

RFE for Classification

```
[ ]:
```

RFE for Regression Use dataset as example: Boston houses

```
[ ]:
```

0.11 Data Save

- Solo si se han hecho cambios
- No aplica

Identificamos los datos a guardar

```
[32]: data_to_save <- data
```

Estructura de nombre de archivos:

- Código del caso de uso, por ejemplo "CU_04"
- Número del proceso que lo genera, por ejemplo "_06".
- Resto del nombre del archivo de entrada
- Extensión del archivo

Ejemplo: "CU_04_06_01_01_zonasgeo.json, primer fichero que se genera en la tarea 01 del proceso 05 (Data Collection) para el caso de uso 04 (vacunas) y que se ha transformado en el proceso 06

Importante mantener los guiones bajos antes de proceso, tarea, archivo y nombre

0.11.1 Proceso 16

```
[33]: caso <- "CU_34"  
      proceso <- '_16'  
      tarea <- "_05"
```

```

archivo <- ""
proper <- "_servicios_completo"
extension <- ".csv"

```

OPCION A: Uso del paquete “tcltk” para mayor comodidad

- Buscar carpeta, escribir nombre de archivo SIN extensión (se especifica en el código)
- Especificar sufijo2 si es necesario
- Cambiar datos por datos_xx si es necesario

```

[34]: # file_save <- paste0(caso, proceso, tarea, tcltk::tkgetSaveFile(), proper,
      ↪extension)
      # path_out <- paste0(oPath, file_save)
      # write_csv(data_to_save_XXXXX, path_out)

      # cat('File saved as: ')
      # path_out

```

OPCION B: Especificar el nombre de archivo

- Los ficheros de salida del proceso van siempre a Data/Output/.

```

[35]: file_save <- paste0(caso, proceso, tarea, archivo, proper, extension)
      path_out <- paste0(oPath, file_save)
      write_csv(data_to_save, path_out)

      cat('File saved as: ')
      path_out

```

File saved as:

'Data/Output/CU_34_16_05_servicios_completo.csv'

Copia del fichero a Input Si el archivo se va a usar en otros notebooks, copiar a la carpeta Input

```

[36]: path_in <- paste0(iPath, file_save)
      file.copy(path_out, path_in, overwrite = TRUE)

```

TRUE

0.12 REPORT

A continuación se realizará un informe de las acciones realizadas

0.13 Main Actions Carried Out

- Si eran necesarias se han realizado en el proceso 05 por cuestiones de eficiencia
- O bien se hacen en el dominio IV o V para integrar en el pipeline de modelización

0.14 Main Conclusions

- Los datos están listos para la modelización y despliegue

0.15 CODE TO DEPLOY (PILOT)

A continuación se incluirá el código que deba ser llevado a despliegue para producción, dado que se entiende efectúa operaciones necesarias sobre los datos en la ejecución del prototipo

Description

- No hay nada que desplegar en el piloto, ya que estos datos son estáticos o en todo caso cambian con muy poca frecuencia, altamente improbable durante el proyecto.

CODE

[]: