

17.- Feature Extraction_04_06_turismo_origen_completo_v_01

June 11, 2023

#

CU45_Planificación y promoción del destino en base a los patrones en origen de los turistas

Citizenlab Data Science Methodology > III - Feature Engineering Domain *** > # 17.- Feature Extraction

Feature Extraction is the process related to dimensionality reduction (or dimension reduction) that creates a projection of the data (high-dimensional space) resulting in entirely new input features (low-dimensional space), so that the low-dimensional representation retains some meaningful properties of the original data, ideally close to its intrinsic dimension.

0.1 Tasks

Perform LDA-Dimensionality-Reduction - Evaluate a Naive Bayes model - Explore the-change-model-performance-with-the-number-of-selected-components. - Making-a-prediction-with-model-fit-on-data-after-applying-an-LDA-transform.

Perform PCA-Dimensionality-Reduction - Evaluate a Logistic Regression model - Explore the-change-model-performance-with-the-number-of-selected-components. - Making-a-prediction-with-model-fit-on-data-after-applying-an-LDA-transform.

Perform SVD-Dimensionality-Reduction - Evaluate a Logistic Regression model - Explore the-change-model-performance-with-the-number-of-selected-components. - Making-a-prediction-with-model-fit-on-data-after-applying-an-LDA-transform.

0.2 Consideraciones casos CitizenLab programados en R

- Algunas de las tareas de este proceso se han realizado en los notebooks del proceso 05 Data Collection porque eran necesarias para las tareas ETL. En esos casos, en este notebook se referencia al notebook del proceso 05 correspondiente
- Otras tareas típicas de este proceso se realizan en los notebooks del dominio IV al ser más eficiente realizarlas en el propio pipeline de modelización.
- Por tanto en los notebooks de este proceso de manera general se incluyen las comprobaciones necesarias, y comentarios si procede
- Las tareas del proceso se van a aplicar solo a los archivos que forman parte del despliegue, ya que hay muchos archivos intermedios que no procede pasar por este proceso
- El nombre de archivo del notebook hace referencia al nombre de archivo del proceso 05 al que se aplica este proceso, por eso pueden no ser correlativa la numeración
- Las comprobaciones se van a realizar teniendo en cuenta que el lenguaje utilizado en el despliegue de este caso es R

0.3 File

- Input File: CU_45_08_03_turismo_receptor.csv
- Sampled Input File: CU_45_07_03_turismo_receptor.csv
- Output File: No aplica

0.3.1 Encoding

Con la siguiente expresión se evitan problemas con el encoding al ejecutar el notebook. Es posible que deba ser eliminada o adaptada a la máquina en la que se ejecute el código.

```
[52]: Sys.setlocale(category = "LC_ALL", locale = "es_ES.UTF-8")
```

```
Warning message in Sys.setlocale(category = "LC_ALL", locale = "es_ES.UTF-8"):  
"OS reports request to set locale to "es_ES.UTF-8" cannot be honored"  
"
```

0.4 Settings

0.4.1 Libraries to use

```
[53]: library(readr)  
library(dplyr)  
library(tidyr)  
library(forcats)  
library(lubridate)
```

0.4.2 Paths

```
[54]: iPath <- "Data/Input/"  
oPath <- "Data/Output/"
```

0.5 Data Load

OPCION A: Seleccionar fichero en ventana para mayor comodidad

Data load using the {tcltk} package. Ucomment the line if using this option

```
[55]: # file_data <- tcltk::tk_choose.files(multi = FALSE)
```

OPCION B: Especificar el nombre de archivo

```
[56]: iFile <- "CU_45_08_03_turismo_receptor.csv"  
file_data <- paste0(iPath, iFile)  
  
if(file.exists(file_data)){  
  cat("Se leerán datos del archivo: ", file_data)  
} else{  
  warning("Cuidado: el archivo no existe.")  
}
```

```
}
```

Se leerán datos del archivo: Data/Input/CU_45_08_03_turismo_receptor.csv

Data file to dataframe Usar la función adecuada según el formato de entrada (xlsx, csv, json, ...)

```
[ ]: data <- read_csv(file_data)
```

Estructura de los datos:

```
[ ]: data |> glimpse()
```

Muestra de los primeros datos:

```
[ ]: data |> slice_head(n = 5)
```

0.6 LDA Dimensionality Reduction

0.6.1 Evaluating a Naive Bayes model

Selecting number of components

```
[ ]: # Select number of components  
number_components=5
```

Operation

```
[ ]:
```

0.6.2 Exploring the change model performance with the number of selected components.

Selecting number of components

```
[ ]: # Select range of components  
# LDA is limited in the number of components used in the dimensionality  
# reduction to between the number of classes minus one  
# e.g. if num of class in Target=10, range=1..9  
number_components_i=1  
number_components_f=9
```

Operation

```
[ ]:
```

0.6.3 Making a prediction with model fit on data after applying an LDA transform.

Selecting number of components

```
[ ]: # Select number of components  
number_components=9
```

Operation

```
[ ]:
```

0.7 PCA Dimensionality Reduction

0.7.1 Evaluating a Logistic Regression model

Selecting number of components

```
[ ]: # Select number of components  
number_components=10
```

Operation

```
[ ]:
```

0.7.2 Exploring the change model performance with the number of selected components.

Selecting number of components

```
[ ]: # Select range of components  
number_components_i=1  
number_components_f=20
```

Operation

```
[ ]:
```

0.7.3 Making a prediction with model fit on data after applying an LDA transform.

Selecting number of components

```
[ ]: # Select number of components  
number_components=15
```

Operation

```
[ ]:
```

0.8 SVD Dimensionality Reduction

0.8.1 Evaluating a Logistic Regression model

Selecting number of components

```
[ ]: # Select number of components  
number_components=10
```

Operation

```
[ ]:
```

0.8.2 Exploring the change model performance with the number of selected components.

Selecting number of components

```
[ ]: # Select range of components  
number_components_i=1  
number_components_f=19 # max = Number of features - 1
```

Operation

```
[ ]:
```

0.8.3 Making a prediction with model fit on data after applying an LDA transform.

Selecting number of components

```
[ ]: # Select number of components  
number_components=15
```

Operation