# 17.- Feature Extraction\_04\_06\_turismo\_gasto\_completo\_v\_01

June 15, 2023

#

CU55\_Modelo agregado de estimación del gasto medio por turista

Citizenlab Data Science Methodology > III - Feature Engineering Domain \*\*\* > # 17.- Feature Extraction

Feature Extraction is the process related to dimensionality reduction (or dimension reduction) that creates a projection of the data (high-dimensional space) resulting in entirely new input features (low-dimensional space), so that the low-dimensional representation retains some meaningful properties of the original data, ideally close to its intrinsic dimension.

#### 0.1 Tasks

Perform LDA-Dimensionality-Reduction - Evaluate a Naive Bayes model - Explore the-change-model-performance-with-the-number-of-selected-components. - Making-a-prediction-with-model-fit-on-data-after-applying-an-LDA-transform.

Perform PCA-Dimensionality-Reduction - Evaluate a Logistic Regression model - Explore the change-model-performance-with-the-number-of-selected-components. - Making-a-prediction-with-model-fit-on-data-after-applying-an-LDA-transform.

Perform SVD-Dimensionality-Reduction - Evaluate a Logistic Regression model - Explore the-change-model-performance-with-the-number-of-selected-components. - Making-a-prediction-with-model-fit-on-data-after-applying-an-LDA-transform.

# 0.2 Consideraciones casos CitizenLab programados en R

- Algunas de las tareas de este proceso se han realizado en los notebooks del proceso 05 Data Collection porque eran necesarias para las tareas ETL. En esos casos, en este notebook se referencia al notebook del proceso 05 correspondiente
- Otras tareas típicas de este proceso se realizan en los notebooks del dominio IV al ser más eficiente realizarlas en el propio pipeline de modelización.
- Por tanto en los notebooks de este proceso de manera general se incluyen las comprobaciones necesarias, y comentarios si procede
- Las tareas del proceso se van a aplicar solo a los archivos que forman parte del despliegue, ya que hay muchos archivos intermedios que no procede pasar por este proceso
- El nombre de archivo del notebook hace referencia al nombre de archivo del proceso 05 al que se aplica este proceso, por eso pueden no ser correlativa la numeración
- Las comprobaciones se van a realizar teniendo en cuenta que el lenguaje utilizado en el despliegue de este caso es R

#### 0.3 File

- Input File: CU\_55\_08\_03\_gasto\_municipio.csv
- Sampled Input File: CU\_55\_07\_03\_gasto\_municipio.csv
- Output File: No aplica

#### 0.3.1 Encoding

Con la siguiente expresión se evitan problemas con el encoding al ejecutar el notebook. Es posible que deba ser eliminada o adaptada a la máquina en la que se ejecute el código.

```
In [1]: Sys.setlocale(category = "LC_ALL", locale = "es_ES.UTF-8")
    'LC_COLLATE=es_ES.UTF-8;LC_CTYPE=es_ES.UTF-8;LC_MONETARY=es_ES.UTF-8;LC_NUMERIC=C;LC_TIME=es_ES.UTF-8'
```

## 0.4 Settings

#### 0.4.1 Libraries to use

```
0.4.2 Paths
```

#### 0.5 Data Load

} else{

OPCION A: Seleccionar fichero en ventana para mayor comodidad Data load using the {tcltk} package. Ucomment the line if using this option

warning("Cuidado: el archivo no existe.")

Se leerán datos del archivo: Data/Input/CU\_55\_08\_03\_gasto\_municipio.csv

cat("Se leerán datos del archivo: ", file\_data)

Data file to dataframe Usar la función adecuada según el formato de entrada (xlsx, csv, json, ...)

```
In [6]: data <- read_csv(file_data)

Rows: 50294 Columns: 10
Column specification
Delimiter: ","
chr (5): mes, pais_orig_cod, pais_orig, mun_dest, CMUN
dbl (4): mun_dest_cod, turistas, gasto, Target
lgl (1): is_train</pre>
```

Use `spec()` to retrieve the full column specification for this data. Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

#### Estructura de los datos:

Muestra de los primeros datos:

In [8]: data |> slice\_head(n = 5)

	mes	pais_orig_cod	pais_orig	mun_dest_cod	mun_dest
A spec_tbl_df: 5 Œ 10	<chr></chr>	<chr></chr>	<chr></chr>	<dbl></dbl>	<chr></chr>
	2019-08	110	Francia	28161	Valdemoro
	2021-07	010	Total Europa	28176	Villanueva de la Cañada
	2021-07	010	Total Europa	28132	San Martín de la Vega
	2022-01	000	Total	28141	Sevilla la Nueva
	2019-08	128	Rumania	28130	San Fernando de Henares

### 0.6 LDA Dimensionality Reduction

### 0.6.1 Evaluating a Naive Bayes model

Selecting number of components

```
In [9]: # Select number of components
    number_components=5
```

Operation

### 0.6.2 Exploring the change model performance with the number of selected components.

Selecting number of components

Operation

#### 0.6.3 Making a prediction with model fit on data after applying an LDA transform.

Selecting number of components

Operation

# 0.7 PCA Dimensionality Reduction

#### 0.7.1 Evaluating a Logistic Regression model

Selecting number of components

Operation

### 0.7.2 Exploring the change model performance with the number of selected components.

Selecting number of components

Operation

# 0.7.3 Making a prediction with model fit on data after applying an LDA transform.

Selecting number of components

Operation

# 0.8 SVD Dimensionality Reduction

### 0.8.1 Evaluating a Logistic Regression model

Selecting number of components

Operation

### 0.8.2 Exploring the change model performance with the number of selected components.

Selecting number of components

Operation

# 0.8.3 Making a prediction with model fit on data after applying an LDA transform.

Selecting number of components

Operation